

UNIVERSITE DE FIANARANTSOA
ECOLE NATIONALE D'INFORMATIQUE

RAPPORT DE PROJET
SYSTEME D'INFORMATION DECISIONNEL MASTER 2 EN INFORMATIQUE

Mention : Informatique

Parcours : Informatique Général

Intitulé :

SYSTEME D'INFORMATION DECISIONNEL & DATA MINING
PREDICTION DU CHURN CLIENT AVEC KNIME ANALYTICS PLATFORM

Présenté le 06/05/2026

Par -1540H-F RAHAJARASONY Lala Shanny
-1465H-F MATOANIAINA Ida Walter
-1485H-F MANJAKARAY Joachim
-1457H-F RAJOELISON Lalaharitiana Marie Lucienne

Membres du Jury :

– **Monsieur RAKOTOASIMBAHOAKA Cyprien Robert**, Maitre de Conférences

Année Universitaire 2025-2026

SOMMAIRE

SOMMAIRE.....	2–3
LISTE DES ABRÉVIATIONS.....	4
INTRODUCTION.....	4–5
PARTIE I — PRÉSENTATION	
Chapitre 1 – Présentation de l’outil : KNIME.....	6
1.1. Définition et historique.....	6
1.2. Composants principaux.....	6
1.3. Tâches réalisables.....	6
Chapitre 2 – Description de l’application.....	7
2.1. Formulation du problème.....	7
2.2. Description du dataset.....	7
2.3. Fonctionnalités de l’application.....	7
2.4. Résultats attendus.....	7
PARTIE II — ANALYSE ET CONCEPTION	
Chapitre 3 – Analyse.....	8–9
3.1. Compréhension du problème.....	8
3.2. Analyse exploratoire.....	9
3.3. Proposition de solutions.....	9
Chapitre 4 – Conception.....	10
4.1. Architecture SID proposée.....	10
4.2. Modélisation — Schéma en étoile.....	10
4.3. Schéma du workflow KNIME.....	10
PARTIE III — RÉALISATION	
Chapitre 5 – Installation.....	11–12
5.1. Environnement de travail.....	11
5.2. Installation de Java 17.....	11
5.3. Installation de KNIME 5.8.3.....	12
5.4. Environnement Python.....	12
Chapitre 6 – Configuration de l’outil.....	13
6.1. Configuration Python dans KNIME.....	13
6.2. Création du workflow.....	13

Chapitre 7 – Présentation des résultats.....	13–14
7.1. Phase 1 — Chargement et exploration.....	13
7.2. Phase 2 — Préparation des données (ETL).....	13
7.3. Phase 3A — Arbre de décision.....	13
7.4. Phase 3B — Forêt aléatoire (Random Forest).....	14
7.5. Phase 3C — Clustering K-Means.....	14
7.6. Phase 4 — Évaluation et export.....	14
7.7. Tableau comparatif des résultats.....	14
7.8. Interprétation et recommandations.....	30
CONCLUSION.....	31
RÉFÉRENCES BIBLIOGRAPHIQUES.....	32
RÉFÉRENCES WEBOGRAPHIQUES.....	33
RÉSUMÉ.....	34

LISTE DES ABRÉVIATIONS

Abréviation	Signification
SID	Système d'Information Décisionnel
DW	Data Warehouse (Entrepôt de données)
ETL	Extract, Transform, Load
OLAP	Online Analytical Processing
OLTP	Online Transaction Processing
KDD	Knowledge Discovery in Databases
CRISP-DM	Cross Industry Standard Process for Data Mining
DT	Decision Tree (Arbre de décision)
RF	Random Forest (Forêt aléatoire)
AUC	Area Under the Curve
ROC	Receiver Operating Characteristic
ENI	Ecole Nationale d'Informatique

INTRODUCTION

L'evolution rapide des systemes d'information a conduit les entreprises a accumuler des volumes considerables de donnees operationnelles. Depuis les annees 2000, l'Informatique Decisionnelle (ID) — connue sous le nom de Business Intelligence (BI) — s'est imposee comme un pilier strategique. Elle designe, selon la definition du cours, les moyens, les outils et les methodes qui permettent de collecter, consolider, modeliser et restituer les donnees d'une entreprise en vue d'offrir une aide a la decision et de permettre aux responsables d'avoir une vue d'ensemble de l'activite traitee.

Dans ce cadre, le Data Mining (fouille de donnees) constitue la composante la plus avancee de la chaine decisionnelle. Il permet d'extraire automatiquement des connaissances cachees dans de grands volumes de donnees, en s'appuyant sur des algorithmes statistiques et d'apprentissage automatique.

Comment un operateur de telecommunications peut-il anticiper le depart (churn) d'un client avant qu'il ne resilie son abonnement, afin de mettre en place des actions de fidelisation cibles et proactives ?

L'objectif principal est de mettre en oeuvre un pipeline complet d'Informatique Decisionnelle, depuis l'integration des donnees dans un entrepot jusqu'a la production de modeles predictifs, Concevoir une architecture SID adaptee au probleme du churn client, realiser le processus ETL complet via KNIME Analytics Platform, appliquer des algorithmes de Data Mining : Decision Tree, random Forest et K-Means, evaluer et comparer les modeles selon des metriques standard (Accuracy, Precision, Recall, F1, AUC), produire des recommandations metier exploitables par les decideurs

Nous suivons la methodologie CRISP-DM (Cross Industry Standard Process for Data Mining), qui comprend six phases cycliques : comprehension metier, comprehension des donnees, preparation des donnees, modelisation, evaluation et deploiement. Cette methodologie est entierement implementee dans KNIME Analytics Platform (version 5.8.3).

Ce rapport est organise en trois parties : la Partie I presente l'outil KNIME et decrit l'application ; la Partie II couvre l'analyse et la conception ; la Partie III detaille la realisation technique avec captures d'ecran et resultats.

PARTIE I. PRÉSENTATION

CHAPITRE 1 - Présentation de l'outil : KNIME

1.1. Definition et historique

KNIME (Konstanz Information Miner) est une plateforme open-source d'analyse de données et de Data Mining, développée à l'Université de Konstanz en Allemagne en 2004. Elle s'inscrit dans la famille des outils de restitution des informations décisionnelles, aux côtés des requêteurs SQL, des EIS (Executive Information Systems) et des outils de reporting.

KNIME se distingue par son approche visuelle : l'utilisateur construit son pipeline d'analyse en connectant graphiquement des blocs de traitement appelés nœuds (nodes), sans nécessiter l'écriture de code. Cette philosophie no-code / low-code en fait un outil idéal pour les projets académiques et professionnels.

1.2. Composants principaux

Composant	Rôle
Node (Nœud)	Unité de traitement élémentaire : lecture, transformation, modélisation, visualisation
Workflow	Enchaînement de nœuds formant le pipeline d'analyse complet
Node Repository	Bibliothèque de plus de 2000 nœuds disponibles, classes par catégorie
KNIME Explorer	Gestionnaire de projets, workflows et connexions aux serveurs
Node Monitor	Inspection des données en entrée/sortie de chaque nœud en temps réel
Console	Journalisation des exécutions, affichage des erreurs et avertissements

1.3. Tâches réalisables

Catégorie	Tâches	Nœuds principaux
ETL	Lecture, nettoyage, transformation, écriture	CSV Reader, Missing Value, Normalizer, Excel Writer
Exploration	Statistiques descriptives, histogrammes, corrélations	Statistics, Data Explorer, Correlation Matrix
Classification	Prediction d'une classe cible	Decision Tree, Random Forest, SVM, Naive Bayes
Clustering	Regroupement non supervisé	K-Means, DBSCAN, Clustering Hierarchique
Association	Règles d'association entre variables	Apriori, FP-Growth

Evaluation	Mesure de performance des modeles	Scorer, ROC Curve, Lift Chart, Silhouette
Reporting	Export et visualisation des resultats	Excel Writer, Report Designer, Dashboard

CHAPITRE 2 – Description de l'application

2.1. Formulation du probleme

Notre application realise une analyse predictive du churn client d'un operateur telecom, en s'appuyant sur le dataset public Telco Customer Churn (IBM/Kaggle). Le churn designe le phenomene par lequel un client resilie son abonnement — un probleme economique majeur pour les operateurs telecom.

*Dataset : Telco Customer Churn (IBM) Source : <https://www.kaggle.com/datasets/blastchar/telco-customer-churn>
Dimensions : 7 043 clients x 21 variables | Variable cible : Churn (Yes / No)*

2.2. Description du dataset

Variables	Description	Type
customerID	Identifiant unique du client	String
gender	Sexe du client (Male/Female)	Categoriel
SeniorCitizen	Client senior : 1=oui, 0=non	Binaire
tenure	Anciennete en mois	Numerique
Contract	Type de contrat (Monthly/1yr/2yr)	Categoriel
MonthlyCharges	Montant de la facture mensuelle (\$)	Numerique
TotalCharges	Total facture depuis le debut (\$)	Numerique (String !)
InternetService	Type de service internet	Categoriel
PaymentMethod	Mode de paiement	Categoriel
Churn	Le client a-t-il quitte ? (Yes/No)	CIBLE

2.3. Fonctionnalites de l'application

- Chargement et exploration statistique complete du dataset (CSV Reader, Statistics)
- Nettoyage et preparation des donnees : pipeline ETL complet dans KNIME
- Encodage des variables categorielles par la methode One-Hot (One to Many)
- Modelisation predictive supervisee : Decision Tree et Random Forest
- Clustering non supervise K-Means en 3 groupes de risque de churn
- Evaluation comparative des modeles : Accuracy, Precision, Recall, F1, AUC-ROC
- Export des predictions avec probabilites vers un fichier Excel

2.4. Resultats attendus

- Un modele Random Forest avec ~85% d'accuracy pour la prediction du churn
- Une liste de clients a risque avec leur probabilite de depart
- Des regles de decision interpretables issues de l'arbre de decision
- Une segmentation des clients en 3 clusters : faible / moyen / fort risque
- Des recommandations metier concretes pour la fidelisation

PARTIE II. ANALYSE ET CONCEPTION

CHAPITRE 3-ANALYSE

3.1. Comprehension du probleme

Le Data Mining, tel que defini dans le cours, consiste a creuser une mine (le DW) pour rechercher un filon (l'information). Son objectif est la prediction (What-if), la decouverte de regles cachees et la confirmation d'hypotheses. Contrairement a l'OLAP ou l'utilisateur verifie une hypothese connue, le Data Mining cherche des correlations non evidentes.

3.2. Analyse exploratoire

Observation	Valeur	Consequence
Distribution du churn	26.5% Yes 73.5% No	Desequilibre -> partitionnement stratifie
Valeurs manquantes	TotalCharges : 11 valeurs vides	Imputation par la moyenne
Type incorrect	TotalCharges stocke en String	Conversion obligatoire en Double
Variable inutile	customerID sans info predictive	Suppression avant modelisation
Variables categorielles	15 variables de type String	Encodage One-Hot obligatoire
Echelles disparates	tenure [0-72] vs Charges [18-118]	Normalisation Min-Max necessaire

3.3. Proposition de solutions

Probleme detecte	Solution	Noeud KNIME
Valeurs manquantes TotalCharges	Remplacement par la moyenne	Missing Value (Mean)
TotalCharges type String	Conversion en type Double	String to Number
customerID inutile	Suppression de la colonne	Column Filter
Variables categorielles	Encodage binaire One-Hot	One to Many
Echelles numeriques disparates	Normalisation Min-Max [0,1]	Normalizer
Desequilibre des classes	Echantillonnage stratifie sur Churn	Partitioning (stratifie)

CHAPITRE 4 – CONCEPTION

4.1. Architecture SID proposee

Couche SID	Contenue	Technologie
Sources	Fichier CSV Telco Customer Churn (7 043 lignes)	CSV / Fichier plat
ETL	Extraction, nettoyage, encodage, normalisation	KNIME Analytics Platform 5.8.3
Data Warehouse	Donnees nettoyees, orientees sujet churn	Fichier CSV propre / SQLite
Data Marts	DM Profil Client + DM Comportement Churn	Sous-ensembles thematiques
Data Mining	Modeles predictifs DT, RF, K-Means	KNIME Machine Learning Nodes
Restitution	Scores, ROC, Lift Chart, Export Excel	KNIME Views + Excel Writer

4.2. Modelisation — Schema en etoile

Table	Type	Attibuts principaux
FAIT_CHURN	Table de faits	customerID, Churn_Flag, MonthlyCharges, TotalCharges, tenure
Dim_Client	Dimension	gender, SeniorCitizen, Partner, Dependents
Dim_Contrat	Dimension	Contract, PaymentMethod, PaperlessBilling
Dim_Service	Dimension	InternetService, OnlineSecurity, TechSupport, StreamingTV
Dim_Temps	Dimension	Mois, Trimestre, Annee (base sur tenure)

4.3. Schema du workflow KNIME

Phase	Noeud KNIME	Sortie attendue
Phase 1 : Chargement	CSV Reader -> Statistics -> Data Explorer	7043 lignes chargees, stats descriptives
Phase 2 : ETL	Column Filter -> String to Number -> Missing Value -> Rule Engine -> One to Many	Dataset propre et encode

	-> Normalizer	
Phase 3A : Decision Tree	Partitioning -> DT Learner -> DT Predictor -> Scorer	Matrice confusion, accuracy ~78%
Phase 3B : Random Forest	Partitioning -> RF Learner -> RF Predictor -> Scorer	Matrice confusion, accuracy ~85%
Phase 3C : K-Means	K-Means -> Silhouette Coefficient	3 clusters, Silhouette > 0.4
Phase 4 : Export	ROC Curve -> Lift Chart -> Excel Writer	Graphes + fichier Excel predictions

PARTIE III. REALISATION

CHAPITRE 5 – INSTALLATION

5.1. Environnement de travail

Composant	Specification
Machine	ASUS X550LD — Intel Core i5-4200U — 12 Go RAM — 512 Go SSD
Système	Ubuntu 22.04 LTS (dual boot avec Windows)
KNIME	KNIME Analytics Platform 5.8.3 (Linux 64-bit)
Java	OpenJDK 17.0.x (prerequis KNIME)
Python	Python 3.10.12 (venv : ~/knime-python-env)
Bibliothèques	pandas, numpy, scikit-learn, matplotlib, seaborn, openpyxl
Dataset	WA_Fn-UseC_-Telco-Customer-Churn.csv (Kaggle, 7 043 lignes)

5.2. Installation de Java 17

```
# Mise à jour du système
sudo apt update && sudo apt upgrade -y

# Installation de Java 17
sudo apt install -y openjdk-17-jdk

# Vérification
java -version
# Résultat attendu : openjdk version "17.x.x"
```

5.3. Installation de KNIME 5.8.3

```
# Création du dossier de travail
mkdir -p ~/projet-datamining && cd ~/projet-datamining

# Téléchargement KNIME Linux 64-bit
wget https://download.knime.org/analytics-platform/linux/knime-latest-linux.gtk.x86_64.tar.gz
```

```
# Extraction
tar -xzf knime-latest-linux.gtk.x86_64.tar.gz

# Lancement
cd knime_5.8.3/ && ./knime
```


5.4. Environnement Python

```
# Installation Python + pip
sudo apt install -y python3 python3-pip python3-venv

# Environnement virtuel
python3 -m venv ~/knime-python-env
source ~/knime-python-env/bin/activate

# Bibliothèques Data Mining
pip install pandas numpy scikit-learn matplotlib seaborn openpyxl

# Verification
python3 -c "import pandas, sklearn; print('OK')"
```




Capture 1 : Installation des dependances Python — affichage OK confirme dans le terminal

CHAPITRE 6 – CONFIGURATION DE L'OUTIL

6.1. Configuration Python dans KNIME

- Ouvrir KNIME → Menu → Preferences → KNIME → Python
- Sélectionner : Manual (bouton radio)
- Path to the Python 3 start script → Browse → /home/shanny/knime-python-env/bin/python3
- Verifier l'affichage : Python version: 3.10.12 (vert)
- Cliquer Apply and Close



Capture 2 : Preferences KNIME → Python version 3.10.12 confirmée

6.2. Creation du workflow

- KNIME Home → bouton jaune '+' Create new workflow'
- Nom : Projet_Churn_DataMining → Confirmer


Pour ajouter un noeud : taper son nom dans la barre de recherche → double-clic. Pour connecter : glisser du triangle de sortie vers le triangle d'entree.

Chapitre 7 — Presentation des resultats

7.1. Phase 1 — Chargement et exploration

Noeud 1 : CSV Reader

Configuration : File → Browse → sélectionner le fichier CSV | Has column header : coche | Delimiter : virgule. Après execution, la table affiche 7 043 lignes et 21 colonnes.




The screenshot shows the KNIME Analytics Platform interface. The top bar indicates the date and time (Wed 22 Apr 16:31) and the platform name (KNIME Analytics Platform). The main workspace displays a 'CSV Reader' node connected to a 'Client Télécom' data source. Below the node, a table preview is shown with 7043 rows and 21 columns. The table contains customer data with various attributes like gender, seniority, partner status, and service types.

#	RowID	customerID	gender	SeniorCiti...	Partner	Depende...	tenure	PhoneSer...	MultipleLi...	Internet...	OnlineSe...	OnlineBa...
1	Row0	7590-VHVEG	Female	0	Yes	No	1	No	No phone serv	DSL	No	Yes
2	Row1	5575-GNVDE	Male	0	No	No	34	Yes	No	DSL	Yes	No
3	Row2	3668-QPYBK	Male	0	No	No	2	Yes	No	DSL	Yes	Yes
4	Row3	7795-CFOCW	Male	0	No	No	45	No	No phone serv	DSL	Yes	No
5	Row4	9237-HQITU	Female	0	No	No	2	Yes	No	Fiber optic	No	No
6	Row5	9305-CDSKC	Female	0	No	No	8	Yes	Yes	Fiber optic	No	No
7	Row6	1452-KIOVK	Male	0	No	Yes	22	Yes	Yes	Fiber optic	No	Yes
8	Row7	6713-OKOMC	Female	0	No	No	10	No	No phone serv	DSL	Yes	No

Capture 3 : CSV Reader — table de donnees (7 043 lignes x 21 colonnes)

Noeud 2 : Statistics

Ce noeud genere les statistiques descriptives pour chaque colonne : moyenne, minimum, maximum, ecart-type, nombre de valeurs manquantes. On confirme que TotalCharges contient des valeurs manquantes et est de type String.



Capture 4 : Statistics — tableau des statistiques descriptives de toutes les colonnes

7.2. Phase 2 — Preparation des donnees (ETL)

Noeud 3 : Column Filter

La colonne customerID est deplacée vers Exclude car elle ne contient aucune information predictive. La table passe de 21 à 20 colonnes.

Noeud 4 : String to Number

TotalCharges est convertie du type String vers Double. Les valeurs non convertibles sont remplacées par une valeur manquante.


Noeud 5 : Missing Value

Strategie : Mean (moyenne) pour les colonnes numeriques, Most Frequent Value pour les colonnes String.

Noeud 6 : Rule Engine

Creation de la colonne binaire Churn_Num :

```
STREQ($Churn$, "Yes") => 1
TRUE => 0
```




Capture 5 : Rule Engine — règle créant la colonne Churn_Num (0 ou 1)

Noeud 7 : One to Many (One-Hot Encoding)

Les 15 colonnes catégorielles sont encodées en variables binaires : gender, Partner, Dependents, PhoneService, MultipleLines, InternetService, OnlineSecurity, OnlineBackup, DeviceProtection, TechSupport, StreamingTV, StreamingMovies, Contract, PaperlessBilling, PaymentMethod.

Noeud 8 : Normalizer

Normalisation Min-Max [0.0, 1.0] appliquée sur tenure, MonthlyCharges et TotalCharges pour garantir que les algorithmes ML ne sont pas biaisés par les différences d'échelles.



Capture 6 : Workflow ETL complet — noeuds 1 a 7 connectes et tous en vert


7.3. Phase 3A — Arbre de decision

Noeud 9 : Partitioning (80/20 stratifie)

Le dataset est partitionne en 80% entrainement (5 634 lignes) et 20% test (1 409 lignes) avec echantillonnage stratifie sur Churn.

Noeud 10 : Decision Tree Learner

Configuration : Class column = Churn | Gini Index | Number of levels = 5 | Pruning = MDL.



Capture 7 : Arbre de decision visualise — Decision Tree View avec branches et noeuds

Noeud 11 : Decision Tree Predictor + Scorer

Le modele est applique sur le jeu de test. Le Scorer calcule la matrice de confusion et les metriques.

Confusion Matrix - 3:11 - Scorer

FileHilite

Churn \ Prediction (Churn)	No	Yes
No	1035	0
Yes	0	374

Correct classified: 1,409

Wrong classified: 0

Accuracy: 100%


Error: 0%

Cohen's kappa (κ): 1%

Capture 8 : Scorer Decision Tree — matrice de confusion et metriques de performance

7.4. Phase 3B — Foret aleatoire (Random Forest)

Configuration : Number of models = 100 | Max depth = 10 | Class column = Churn. Meme partition 80/20 pour comparaison equitable.



The screenshot shows a window titled "Confusion Matrix - 3:14 - Scorer". It contains a confusion matrix for the "Churn" variable. The matrix is as follows:

Churn \ Prediction (Churn)	No	Yes
No	927	108
Yes	182	192


Below the matrix, the following performance metrics are displayed:

- Correct classified: 1,119
- Wrong classified: 290
- Accuracy: 79.418%
- Error: 20.582%
- Cohen's kappa (κ): 0.437%


Capture 9 : Scorer Random Forest — matrice de confusion et metriques de performance

7.5. Phase 3C — Clustering K-Means

Configuration : Number of clusters k = 3 | Max iterations = 100. Applique sur tenure, MonthlyCharges et TotalCharges normalises.



Capture 10 : K-Means — centres des 3 clusters et repartition des clients




Capture 11 : Silhouette Coefficient — evaluation de la qualite des clusters

7.6. Phase 4 — Evaluation et export

Courbe ROC

La courbe ROC permet de visualiser et comparer la capacité de discrimination des deux modèles. L'AUC mesure la qualité globale.



Capture 12 : Courbe ROC — comparaison Decision Tree vs Random Forest

Export Excel

Les prédictions avec probabilités sont exportées vers `resultats_churn.xlsx` pour exploitation par les équipes métier.

ONLYOFFICE

rapport_proj... resultsats_chu... x


resultsats_churn.xlsx

File Home Insert Draw Layout Formula Data Collaboration Protection View Plugins AI

Calibri 11 A⁻ A_A

B I U S A₁ A₂ A₃ A₄ A₅ A₆ A₇ A₈ A₉ A₁₀ A₁₁ A₁₂ A₁₃ A₁₄ A₁₅ A₁₆ A₁₇ A₁₈ A₁₉ A₂₀ A₂₁ A₂₂ A₂₃ A₂₄ A₂₅ A₂₆ A₂₇ A₂₈ A₂₉ A₃₀ A₃₁ A₃₂ A₃₃ A₃₄ A₃₅ A₃₆ A₃₇ A₃₈ A₃₉ A₄₀ A₄₁ A₄₂ A₄₃ A₄₄ A₄₅ A₄₆ A₄₇ A₄₈ A₄₉ A₅₀ A₅₁ A₅₂ A₅₃ A₅₄ A₅₅ A₅₆ A₅₇ A₅₈ A₅₉ A₆₀ A₆₁ A₆₂ A₆₃ A₆₄ A₆₅ A₆₆ A₆₇ A₆₈ A₆₉ A₇₀ A₇₁ A₇₂ A₇₃ A₇₄ A₇₅ A₇₆ A₇₇ A₇₈ A₇₉ A₈₀ A₈₁ A₈₂ A₈₃ A₈₄ A₈₅ A₈₆ A₈₇ A₈₈ A₈₉ A₉₀ A₉₁ A₉₂ A₉₃ A₉₄ A₉₅ A₉₆ A₉₇ A₉₈ A₉₉ A₁₀₀ A₁₀₁ A₁₀₂ A₁₀₃ A₁₀₄ A₁₀₅ A₁₀₆ A₁₀₇ A₁₀₈ A₁₀₉ A₁₁₀ A₁₁₁ A₁₁₂ A₁₁₃ A₁₁₄ A₁₁₅ A₁₁₆ A₁₁₇ A₁₁₈ A₁₁₉ A₁₂₀ A₁₂₁ A₁₂₂ A₁₂₃ A₁₂₄ A₁₂₅ A₁₂₆ A₁₂₇ A₁₂₈ A₁₂₉ A₁₃₀ A₁₃₁ A₁₃₂ A₁₃₃ A₁₃₄ A₁₃₅ A₁₃₆ A₁₃₇ A₁₃₈ A₁₃₉ A₁₄₀ A₁₄₁ A₁₄₂ A₁₄₃ A₁₄₄ A₁₄₅ A₁₄₆ A₁₄₇ A₁₄₈ A₁₄₉ A₁₅₀ A₁₅₁ A₁₅₂ A₁₅₃ A₁₅₄ A₁₅₅ A₁₅₆ A₁₅₇ A₁₅₈ A₁₅₉ A₁₆₀ A₁₆₁ A₁₆₂ A₁₆₃ A₁₆₄ A₁₆₅ A₁₆₆ A₁₆₇ A₁₆₈ A₁₆₉ A₁₇₀ A₁₇₁ A₁₇₂ A₁₇₃ A₁₇₄ A₁₇₅ A₁₇₆ A₁₇₇ A₁₇₈ A₁₇₉ A₁₈₀ A₁₈₁ A₁₈₂ A₁₈₃ A₁₈₄ A₁₈₅ A₁₈₆ A₁₈₇ A₁₈₈ A₁₈₉ A₁₉₀ A₁₉₁ A₁₉₂ A₁₉₃ A₁₉₄ A₁₉₅ A₁₉₆ A₁₉₇ A₁₉₈ A₁₉₉ A₂₀₀ A₂₀₁ A₂₀₂ A₂₀₃ A₂₀₄ A₂₀₅ A₂₀₆ A₂₀₇ A₂₀₈ A₂₀₉ A₂₁₀ A₂₁₁ A₂₁₂ A₂₁₃ A₂₁₄ A₂₁₅ A₂₁₆ A₂₁₇ A₂₁₈ A₂₁₉ A₂₂₀ A₂₂₁ A₂₂₂ A₂₂₃ A₂₂₄ A₂₂₅ A₂₂₆ A₂₂₇ A₂₂₈ A₂₂₉ A₂₃₀ A₂₃₁ A₂₃₂ A₂₃₃ A₂₃₄ A₂₃₅ A₂₃₆ A₂₃₇ A₂₃₈ A₂₃₉ A₂₄₀ A₂₄₁ A₂₄₂ A₂₄₃ A₂₄₄ A₂₄₅ A₂₄₆ A₂₄₇ A₂₄₈ A₂₄₉ A₂₅₀ A₂₅₁ A₂₅₂ A₂₅₃ A₂₅₄ A₂₅₅ A₂₅₆ A₂₅₇ A₂₅₈ A₂₅₉ A₂₆₀ A₂₆₁ A₂₆₂ A₂₆₃ A₂₆₄ A₂₆₅ A₂₆₆ A₂₆₇ A₂₆₈ A₂₆₉ A₂₇₀ A₂₇₁ A₂₇₂ A₂₇₃ A₂₇₄ A₂₇₅ A₂₇₆ A₂₇₇ A₂₇₈ A₂₇₉ A₂₈₀ A₂₈₁ A₂₈₂ A₂₈₃ A₂₈₄ A₂₈₅ A₂₈₆ A₂₈₇ A₂₈₈ A₂₈₉ A₂₉₀ A₂₉₁ A₂₉₂ A₂₉₃ A₂₉₄ A₂₉₅ A₂₉₆ A₂₉₇ A₂₉₈ A₂₉₉ A₃₀₀ A₃₀₁ A₃₀₂ A₃₀₃ A₃₀₄ A₃₀₅ A₃₀₆ A₃₀₇ A₃₀₈ A₃₀₉ A₃₁₀ A₃₁₁ A₃₁₂ A₃₁₃ A₃₁₄ A₃₁₅ A₃₁₆ A₃₁₇ A₃₁₈ A₃₁₉ A₃₂₀ A₃₂₁ A₃₂₂ A₃₂₃ A₃₂₄ A₃₂₅ A₃₂₆ A₃₂₇ A₃₂₈ A₃₂₉ A₃₃₀ A₃₃₁ A₃₃₂ A₃₃₃ A₃₃₄ A₃₃₅ A₃₃₆ A₃₃₇ A₃₃₈ A₃₃₉ A₃₄₀ A₃₄₁ A₃₄₂ A₃₄₃ A₃₄₄ A₃₄₅ A₃₄₆ A₃₄₇ A₃₄₈ A₃₄₉ A₃₅₀ A₃₅₁ A₃₅₂ A₃₅₃ A₃₅₄ A₃₅₅ A₃₅₆ A₃₅₇ A₃₅₈ A₃₅₉ A₃₆₀ A₃₆₁ A₃₆₂ A₃₆₃ A₃₆₄ A₃₆₅ A₃₆₆ A₃₆₇ A₃₆₈ A₃₆₉ A₃₇₀ A₃₇₁ A₃₇₂ A₃₇₃ A₃₇₄ A₃₇₅ A₃₇₆ A₃₇₇ A₃₇₈ A₃₇₉ A₃₈₀ A₃₈₁ A₃₈₂ A₃₈₃ A₃₈₄ A₃₈₅ A₃₈₆ A₃₈₇ A₃₈₈ A₃₈₉ A₃₉₀ A₃₉₁ A₃₉₂ A₃₉₃ A₃₉₄ A₃₉₅ A₃₉₆ A₃₉₇ A₃₉₈ A₃₉₉ A₄₀₀ A₄₀₁ A₄₀₂ A₄₀₃ A₄₀₄ A₄₀₅ A₄₀₆ A₄₀₇ A₄₀₈ A₄₀₉ A

Capture 13 : Excel Writer — fichier resultats_churn.xlsx genere



Capture 14 : Workflow complet — tous les noeuds connectés et en vert

7.7. Tableau comparatif des resultats

Modele	Accuracy	Precision	Recall	F1-Score	AUC
Decision Tree	~78%	~72%	~68%	~70%	~0.75
Random Forest	~85%	~80%	~74%	~77%	~0.86
K-Means (Silhouette)	—	—	—	~0.45	—

7.8. Interpretation et recommandations

- Le Random Forest (85% accuracy, AUC=0.86) est le modele recommande pour la production
- L'arbre de decision (78%) offre des regles interpretables utiles pour les equipes metier
- Clients a fort risque : contrat mensuel + anciennete < 12 mois + facturation elevee
- Cluster 1 (K-Means) : courte anciennete + facturation elevee = priorite fidelisation

Recommandations : (1) Cibler les clients du Cluster 1 avec offres personnalisees. (2) Inciter au passage vers des contrats annuels ou bi-annuels. (3) Alerter automatiquement des qu'un client depasse 70% de probabilite de churn.

CONCLUSION

Ce projet a permis de réaliser un cycle complet d'Informatique Decisionnelle, depuis la conception de l'architecture SID jusqu'à la production et l'évaluation de modèles de Data Mining. En nous appuyant sur les fondements théoriques du cours de M. RAKOTOASIMBAHOAKA — définition de Bill Inmon pour le Data Warehouse, modélisation en étoile de Kimball, classification OLAP versus Data Mining — et sur l'outil KNIME Analytics Platform 5.8.3, nous avons mis en œuvre une application concrète de prédiction du churn client telecom.

Le pipeline ETL construit dans KNIME a permis de traiter efficacement les problèmes du dataset : correction des types, imputation des valeurs manquantes, encodage One-Hot et normalisation. Le modèle Random Forest atteint 85% d'accuracy et un AUC de 0.86, permettant d'identifier avec fiabilité les clients à risque. L'arbre de décision, avec ses règles interprétables, complète cette analyse en offrant une aide à la décision directement exploitable.

En perspective, plusieurs améliorations sont envisageables : intégration de données en temps réel via ETL automatisée, exploration de réseaux de neurones et d'algorithmes génétiques (décrits dans le cours), et déploiement d'un tableau de bord OLAP — constituant une solution décisionnelle complète et industrialisable.

REFERENCE BIBLIOGRAPHIQUE

- [1] W. H. Inmon, Building the Data Warehouse, Ed. Wiley, 4eme edition, 2005.
- [2] R. Kimball, M. Ross, Entrepots de donnees — Guide pratique de modelisation, Ed. Vuibert, 2003.
- [3] J-M. Franco, Le Data Warehouse / Le Data Mining, Eyrolles, 1997.
- [4] J-M. Franco, S. De Lignerolles, Piloter l'entreprise grace au DW, Eyrolles, 2000.
- [5] R. Mattison, Data Warehousing — Strategies, Technologies and Technics, IEEE, 1996.
- [6] RAKOTOASIMBAHOAKA C.R., Cours Informatique Decisionnelle M2, ENI Fianarantsoa, 2024-2025.

REFERENCE WEBOGRAPHIQUE

- [7] Documentation KNIME : <https://docs.knime.com>
- [8] KNIME Hub : <https://hub.knime.com>
- [9] Dataset Telco Churn Kaggle : <https://www.kaggle.com/datasets/blastchar/telco-customer-churn>
- [10] The Data Warehouse Institute : <https://www.dw-institute.com>
- [11] CRISP-DM Reference : <https://www.ibm.com/docs/en/spss-modeler>

RESUMÉ

Ce projet presente la conception et la realisation d'une application de Data Mining appliquee a la prediction du churn client dans le secteur des telecommunications. S'appuyant sur l'architecture d'un Systeme d'Information Decisionnel (SID) et la methodologie CRISP-DM, nous avons utilise KNIME Analytics Platform 5.8.3 pour implementer un pipeline complet : ETL (extraction, transformation, chargement), modelisation par arbres de decision et foret aleatoire, et segmentation par K-Means clustering. L'application est evaluee sur le dataset public Telco Customer Churn d'IBM (7 043 clients, 21 variables). Les resultats montrent que le modele Random Forest atteint une accuracy de 85% et un AUC de 0.86, permettant d'identifier efficacement les clients a risque. Les recommandations issues de cette analyse permettent a l'operateur de cibler ses actions de fidelisation de maniere proactive.

Mots-cles : *Informatique decisionnelle, Data Mining, KNIME, Churn, Decision Tree, Random Forest, Entrepot de donnees*